Unsupervised

September 24, 2019

Universidad Nacional de Córdoba - Facultad de Matemática, Astronomía, Física y Computación

Diplomatura en Ciencia de Datos, Aprendizaje Automático y sus Aplicaciones

Práctico 5 - Aprendizaje No Supervisado - 2019

Integrante:

- Tarletta Juan

Trabajaremos con el mismo dataset utilizado en curación de datos (deben utilizar el dataset que se encuentra con los datos modificados o bien aplicar los mismos métodos del trabajo anterior para contar con datos válidos)

El dataset cuenta con X features, siendo las más importantes

- Componente: Indica a que componente pertenece la muestra
- Horas Funcionamiento: Indica la cantidad de horas de funcionamiento del camión (sería como el kilometraje de los camiones)
- Horas del Aceite: Representa la cantidad de horas de utilización del aceite (este dato es importante dado que a medida que, a mayor horas de uso del aceite, el mismo comienza a desgastarse)
- Resultado: (El laboratorio indica si la muestra de aceite está Bien = 1, Regular=2, Mal=3)
- St: Presencia de Hollin en el Aceite
- Al: Presencia de Aluminio en el Aceite
- Fe Presencia de Hierro en el Aceite
- Si Presencia de Silicio en el Aceite
- Na Presencia de Sodio en el Aceite

NOTA: se modifica le dataset y se incluyen el feature * Fecha de Análisis: Indica cuando fué analizada la muestra por el laboratorio

[1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
from IPython.display import display, Markdown

import matplotlib.pyplot as plt
%matplotlib inline
import matplotlib
matplotlib.rcParams['figure.figsize'] = 15, 8
```

[2]:
```
dataset = pd.read_csv('dataset_intro.csv')
important_cols= ['Equipo', 'Componente','Resultado','Horas␣
 ↪Funcionamiento','Horas del Aceite', 'St', 'Al', 'Fe', 'Si', 'Na' ]

#dataset[important_cols]
```

[3]:
```
dataset[['Na']].count()
```

[3]:
```
Na    21432
dtype: int64
```

[4]:
```
import numpy as np
import matplotlib.pyplot as plt

from ml.visualization import plot_confusion_matrix, plot_learning_curve
from sklearn.datasets import load_wine
from sklearn.linear_model import SGDClassifier
from sklearn.metrics import accuracy_score, classification_report,␣
 ↪confusion_matrix
from sklearn.model_selection import GridSearchCV, train_test_split

seed = np.random.seed(1234)

%matplotlib inline
```

[5]:
```
#Obtenemos el componente con más apariciones
compo = dataset[['Componente']].mode()
display(compo)
```

```
  Componente
0      Motor
```

[6]:
```
#Redefinimos el dataset a utilizar, en este caso solo con el componente Motor
dataset = dataset[dataset['Componente'] == 'Motor']
dataset.head(5)
```

[6]:

	Unnamed: 0	Equipo	Componente	Id	Resultado	Horas Funcionamiento	\
3	3	1355	Motor	76.084008	3.0	21950.0	
12	12	1357	Motor	41.099310	1.0	27876.0	
29	29	1356	Motor	82.751875	3.0	28295.0	
49	49	1355	Motor	79.207921	3.0	22729.0	
50	50	1355	Motor	82.456346	2.0	23153.0	

	Horas del Aceite	Fecha de Análisis	B	Nit	...	Zn	Ag	Ti	\
3	409.0	2019-02-20	51.0	9.0	...	1089.0	0.0	0.0	
12	263.0	2017-11-05	NaN	6.0	...	1246.0	0.0	0.0	
29	NaN	2019-05-17	47.0	10.0	...	1122.0	0.0	0.0	
49	380.0	2019-04-03	100.0	6.0	...	1334.0	0.0	0.0	
50	424.0	2019-05-12	105.0	8.0	...	1331.0	0.0	0.0	

```
    V40  V100   TBN  TAN  ISO14  ISO4  ISO6
3   NaN  13.7   9.1  NaN    NaN   NaN   NaN
12  NaN  14.0   NaN  NaN    NaN   NaN   NaN
29  NaN  14.2  10.4  NaN    NaN   NaN   NaN
49  NaN  14.1   9.8  NaN    NaN   NaN   NaN
50  NaN  14.3   9.6  NaN    NaN   NaN   NaN

[5 rows x 45 columns]
```

[7]:
```
dataset.columns
```

[7]:
```
Index(['Unnamed: 0', 'Equipo', 'Componente', 'Id', 'Resultado',
       'Horas Funcionamiento', 'Horas del Aceite', 'Fecha de Análisis', 'B',
       'Nit', 'Oxi', 'Sul', 'St', 'V', 'Al', 'Cr', 'Cu', 'Fe', 'Pb', 'Mo',
       'Ni', 'Sn', 'Si', 'K', 'Na', 'W', 'F', 'A', 'ISO', 'PQI', 'Ba', 'Ca',
       'Mg', 'Mn', 'P', 'Zn', 'Ag', 'Ti', 'V40', 'V100', 'TBN', 'TAN', 'ISO14',
       'ISO4', 'ISO6'],
      dtype='object')
```

[8]:
```
#utilizamos los datos que estan completos de varios features
dataset_reduce = dataset[['Resultado','Horas Funcionamiento','Horas del␣
↪Aceite','Sul', 'V', 'Cr','Cu','Pb','Mo','Ni','K','St','PQI','Al', 'Fe',␣
↪'Si','Ca','Na','Mg', 'Zn','V100','B','Oxi','P']].dropna()
index_dataset_reduce = dataset_reduce.index.values.astype(int)
index_dataset_reduce.shape
```

[8]:
```
(1982,)
```

A continuación evaluaremos k-means sobre el dataset de motor con varios Features.

[9]:
```
from sklearn.cluster import KMeans
from sklearn.metrics import accuracy_score

seed
X = dataset_reduce
y = dataset_reduce['Resultado'] #Feature 'Resultado'
#Utilizaremos 2 Clusters
y_pred = KMeans(n_clusters=3, random_state=seed).fit_predict(X)

# Accuracy de KMeans
accuracy_kmeans = accuracy_score(y, y_pred)

print('Accuracy KMeans para el X_test: {}'.format(accuracy_kmeans))

plt.figure(figsize=(14, 14))
plt.subplot(221)
plt.scatter(X['Horas Funcionamiento'], X['Fe'], c=y_pred)
plt.title("Clusterización sobre el conjunto X_train")
```

```
plt.xlabel('Horas de Funcionamiento')
plt.ylabel('Valores de Hierro')
sns.despine()
```

```
Accuracy KMeans para el X_test: 0.1437941473259334
```

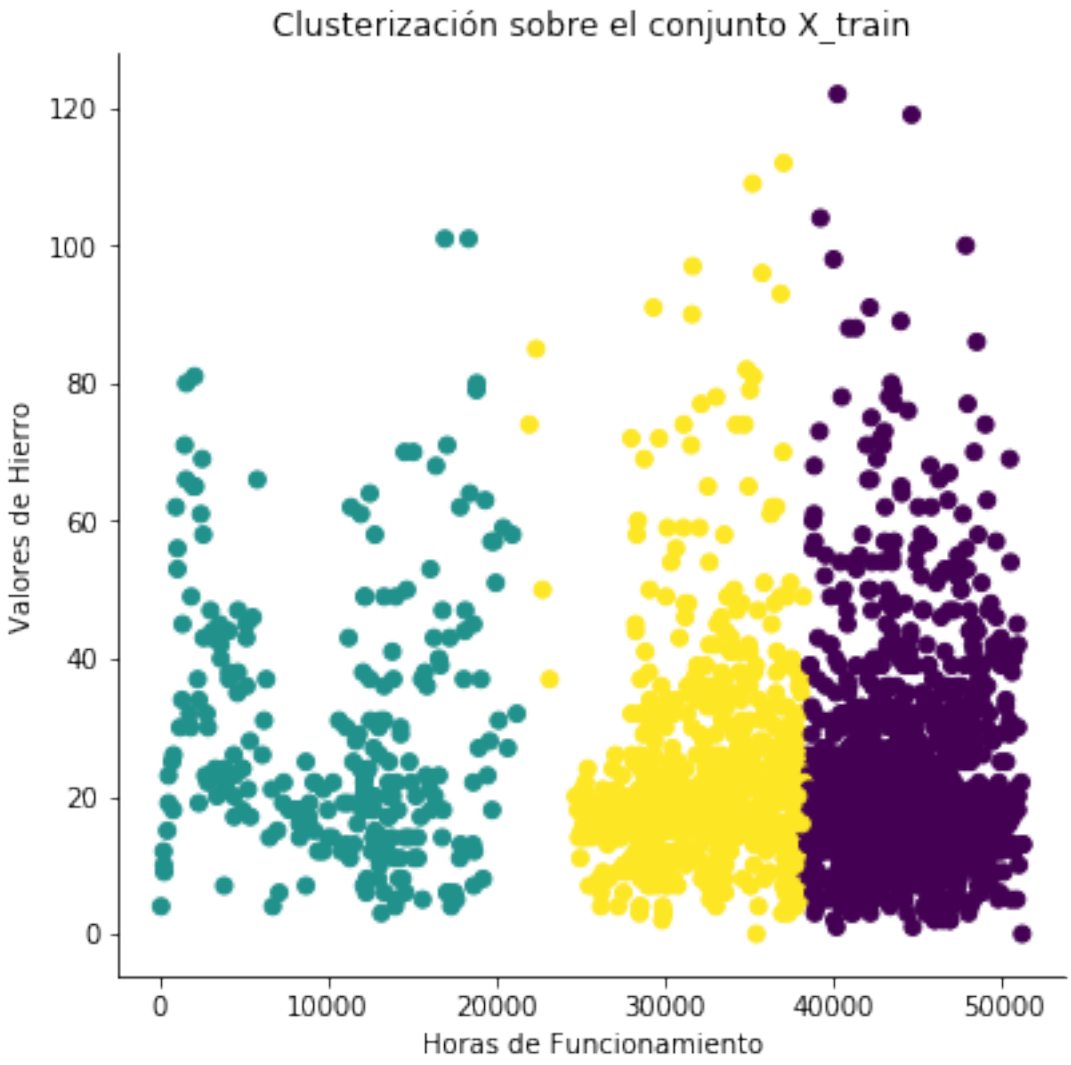

El grafico es solo de referencia pero no es representativo del dataset, de todas formas observamos que el accuracy no es bueno.

Como 'buscamos' que la agrupacion del dataset se haga en base a la calidad de aceite, vamos a descartar algunos features que pueden estar metiendonos 'ruido'.

[10]:
```
#utilizamos los datos que estan completos de varios features
dataset_reduce = dataset[['Resultado','Horas Funcionamiento','Horas del␣
 ↪Aceite','St','Al', 'Fe', 'Si','Ca','Na']].dropna()
index_dataset_reduce = dataset_reduce.index.values.astype(int)
```

```
index_dataset_reduce.shape
```

[10]:
```
(1983,)
```

[11]:
```
from sklearn.cluster import KMeans
from sklearn.metrics import accuracy_score

seed
X = dataset_reduce
y = dataset_reduce['Resultado'] #Feature 'Resultado'
#Utilizaremos n Clusters
y_pred = KMeans(n_clusters=3, random_state=seed).fit_predict(X)

# Accuracy de KMeans
accuracy_kmeans = accuracy_score(y, y_pred)

print('Accuracy KMeans para el X_test: {}'.format(accuracy_kmeans))

plt.figure(figsize=(14, 14))
plt.subplot(221)
plt.scatter(X['Horas Funcionamiento'], X['Fe'], c=y_pred)
plt.title("Clusterización sobre el conjunto X_train")
plt.xlabel('Horas de Funcionamiento')
plt.ylabel('Valores de Hierro')
sns.despine()
```

```
Accuracy KMeans para el X_test: 0.1956631366616238
```

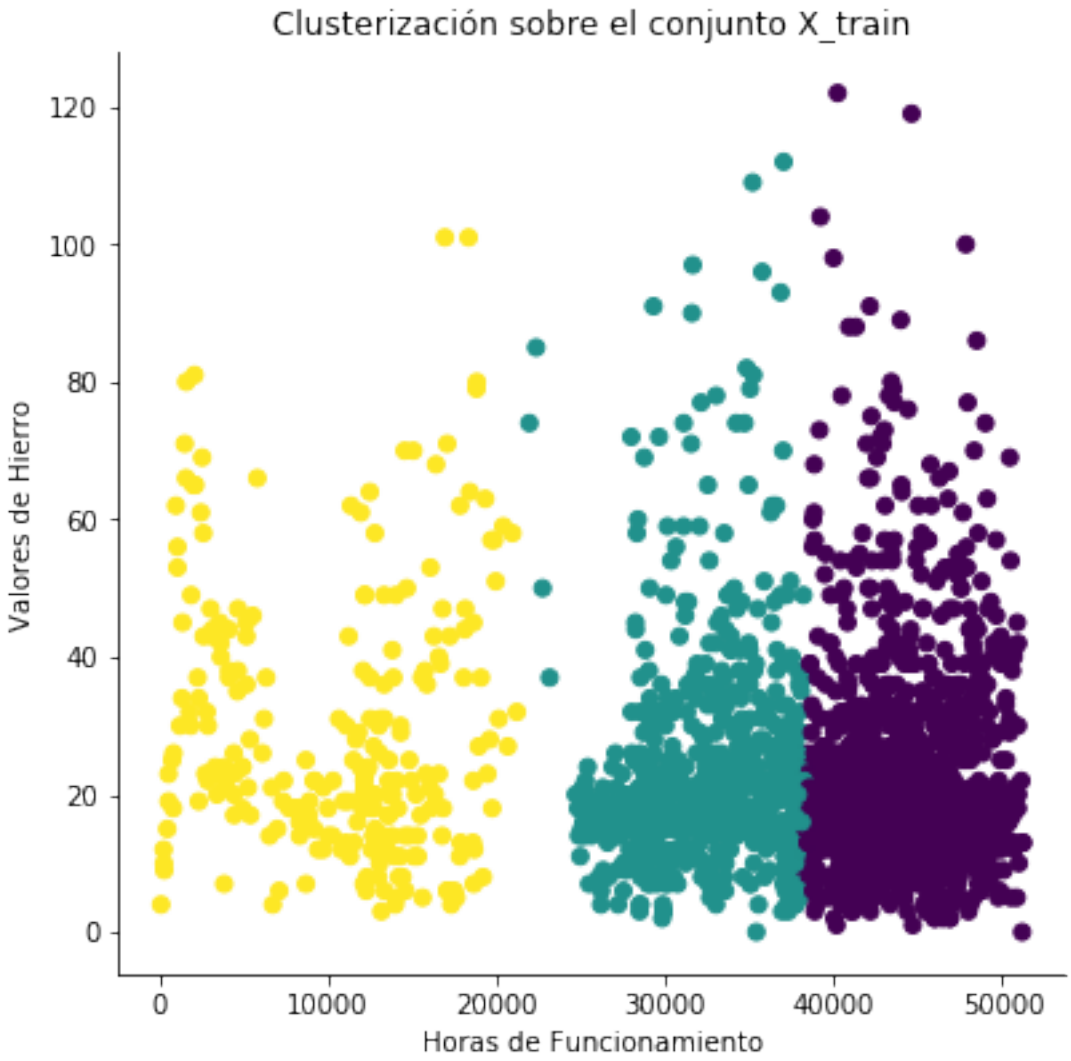

Observamos que por más que reduzcamos los features, (y que esté contenido el feature 'Resultado' en el dataset), el accuracy sigue siendo malo

A continuacion realizaremos scalado/normalizado de los valores, para evitar que algún feature tenga más peso en la distancia a los centroides

[12]:
```
#Separamos el dataset
X = dataset_reduce
Y = dataset_reduce['Resultado'] #Feature 'Resultado'
```

[13]:
```
#Escalamos/Normalizamos los datos
from sklearn import preprocessing

scaler = preprocessing.StandardScaler().fit(X)

# Transformamos los datos de entrenamiento (Media=0 y Desviación_Estandar=1)
X_scaled = scaler.transform(X)
```

[14]:
```
#Clusterizamos con el dataset escalado
y_pred = KMeans(n_clusters=3, random_state=seed).fit_predict(X_scaled)

# Accuracy de KMeans
accuracy_kmeans = accuracy_score(y, y_pred)

print('Accuracy KMeans para el X_test: {}'.format(accuracy_kmeans))

plt.figure(figsize=(14, 14))
plt.subplot(221)
plt.scatter(X['Horas Funcionamiento'], X['Fe'], c=y_pred)
plt.title("Clusterización sobre el conjunto X_train")
plt.xlabel('Horas de Funcionamiento')
plt.ylabel('Valores de Hierro')
sns.despine()
```

```
Accuracy KMeans para el X_test: 0.5370650529500757
```

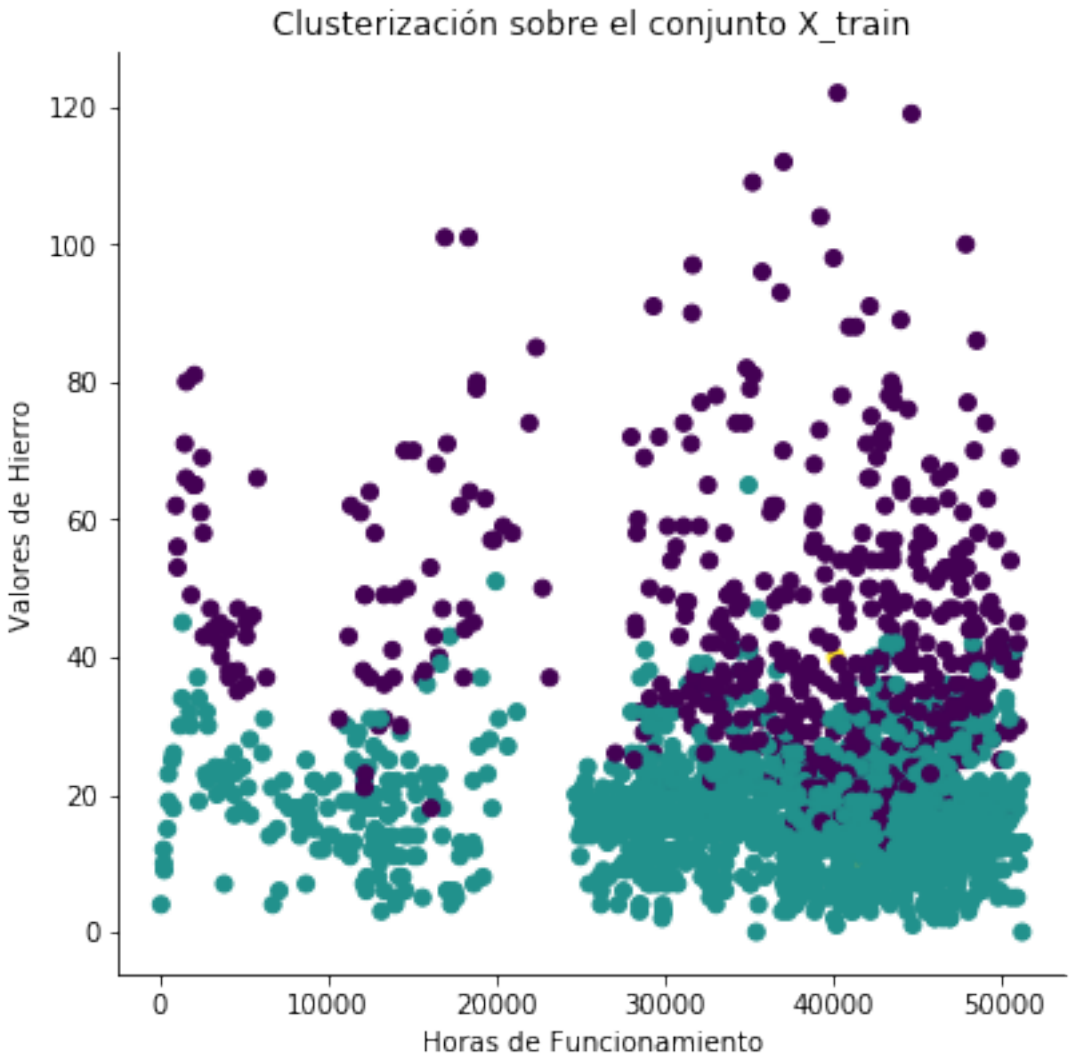

Podemos observar una mejora en los resultados

A continuación aplicaremos PCA para obtener features que nos brinden mayor variabilidad en el dataset

[15]:
```
X = dataset_reduce.iloc[:,1:] #Features sin 'Resultado'
y = dataset_reduce['Resultado'] #Feature 'Resultado'
```

[16]:
```
from sklearn.decomposition import PCA as sklearnPCA
sklearn_pca = sklearnPCA(n_components=3)
X_pca_sklearn = sklearn_pca.fit_transform(X)
X_pca_sklearn.shape
```

[16]:
```
(1983, 3)
```

[17]:
```
#Clusterizamos con el dataset PCA
y_pred = KMeans(n_clusters=3, random_state=seed).fit_predict(X_pca_sklearn)

print(sklearn_pca.singular_values_, sklearn_pca.explained_variance_ratio_)
# Accuracy de KMeans
accuracy_kmeans = accuracy_score(y, y_pred)

print('Accuracy KMeans para el X_test: {}'.format(accuracy_kmeans))

plt.figure(figsize=(14, 14))
plt.subplot(221)
plt.scatter(X['Horas Funcionamiento'], X['Fe'], c=y_pred)
plt.title("Clusterización sobre el conjunto X_train")
plt.xlabel('Horas de Funcionamiento')
plt.ylabel('Valores de Hierro')
sns.despine()
```

```
[516532.3837571   13377.52045999   5919.69385633] [9.99077526e-01 6.70124241e-04
1.31220768e-04]
Accuracy KMeans para el X_test: 0.4402420574886536
```

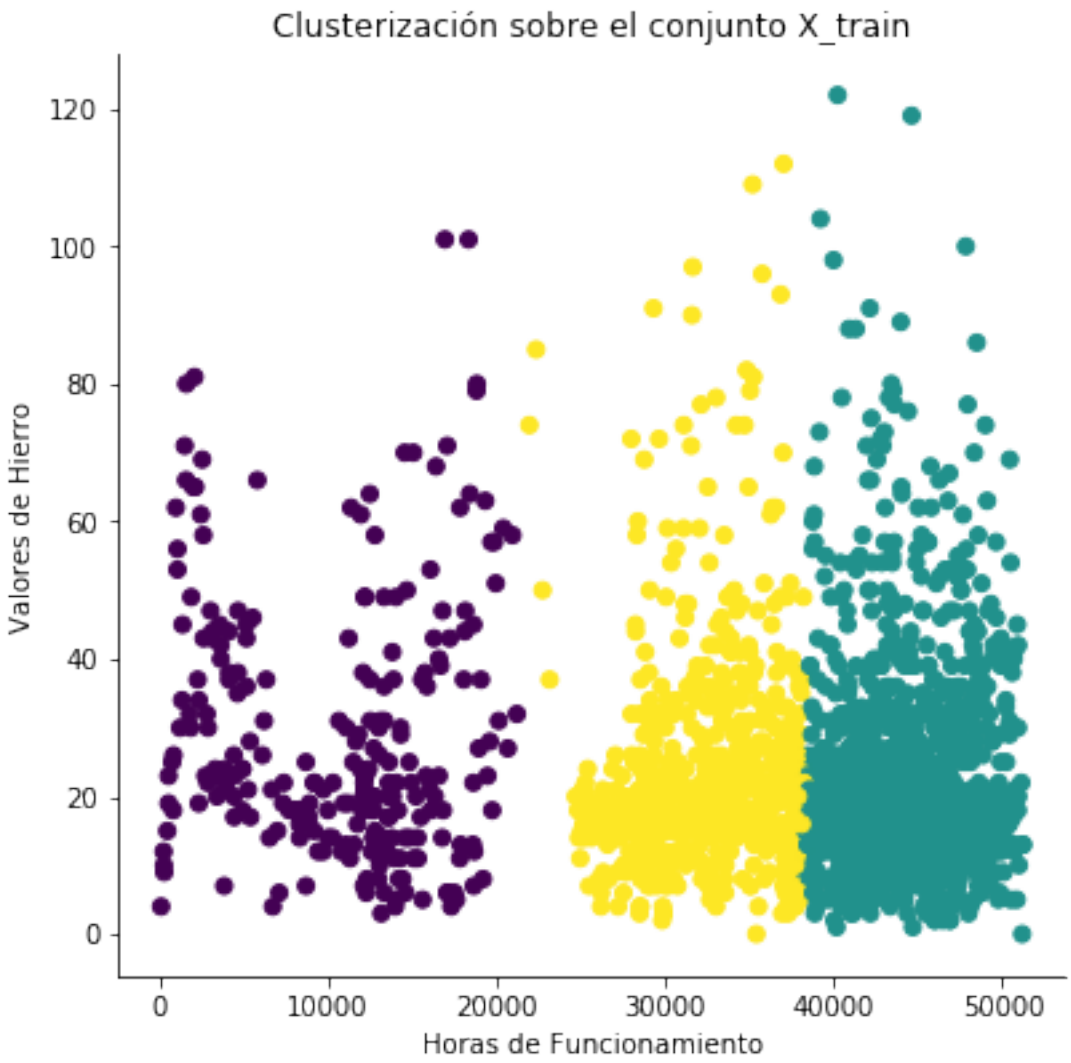

No observamos mejora con PCA, solo que tenemos un solo feature que nos representa el 99% de la variabilidad en los datos

A continuación realizaremos PCA pero con los datos escalados

[18]:
```
#Separamos el dataset
X = dataset_reduce.iloc[:,1:]
Y = dataset_reduce['Resultado'] #Feature 'Resultado'
```

[19]:
```
#Escalamos/Normalizamos los datos
from sklearn import preprocessing

scaler = preprocessing.StandardScaler().fit(X)

# Transformamos los datos de entrenamiento (Media=0 y Desviación_Estandar=1)
X_scaled = scaler.transform(X)
```

[20]:
```
sklearn_pca = sklearnPCA(n_components=5)
X_pca_sklearn = sklearn_pca.fit_transform(X_scaled)
X_pca_sklearn.shape
```

[20]:
```
(1983, 5)
```

[42]:
```
print(sklearn_pca.singular_values_, sklearn_pca.explained_variance_ratio_)

y_pred = KMeans(n_clusters=3, random_state=seed).fit_predict(X_pca_sklearn)

# Accuracy de KMeans
accuracy_kmeans = accuracy_score(y, y_pred)

print('Accuracy KMeans para el X_test: {}'.format(accuracy_kmeans))

plt.figure(figsize=(14, 14))
plt.subplot(221)
plt.scatter(X['Horas Funcionamiento'], X['Fe'], c=y_pred)
plt.title("Clusterización sobre el conjunto scalado y con reduccion de␣
 ↪dimensionalidad")
plt.xlabel('Horas de Funcionamiento')
plt.ylabel('Valores de Hierro')
sns.despine()
```

```
[68.26731915 56.76908018 47.83255803 43.67988954 41.97783209] [0.29377376
0.20314728 0.144223   0.12026808 0.11107781]
Accuracy KMeans para el X_test: 0.642965204236006
```

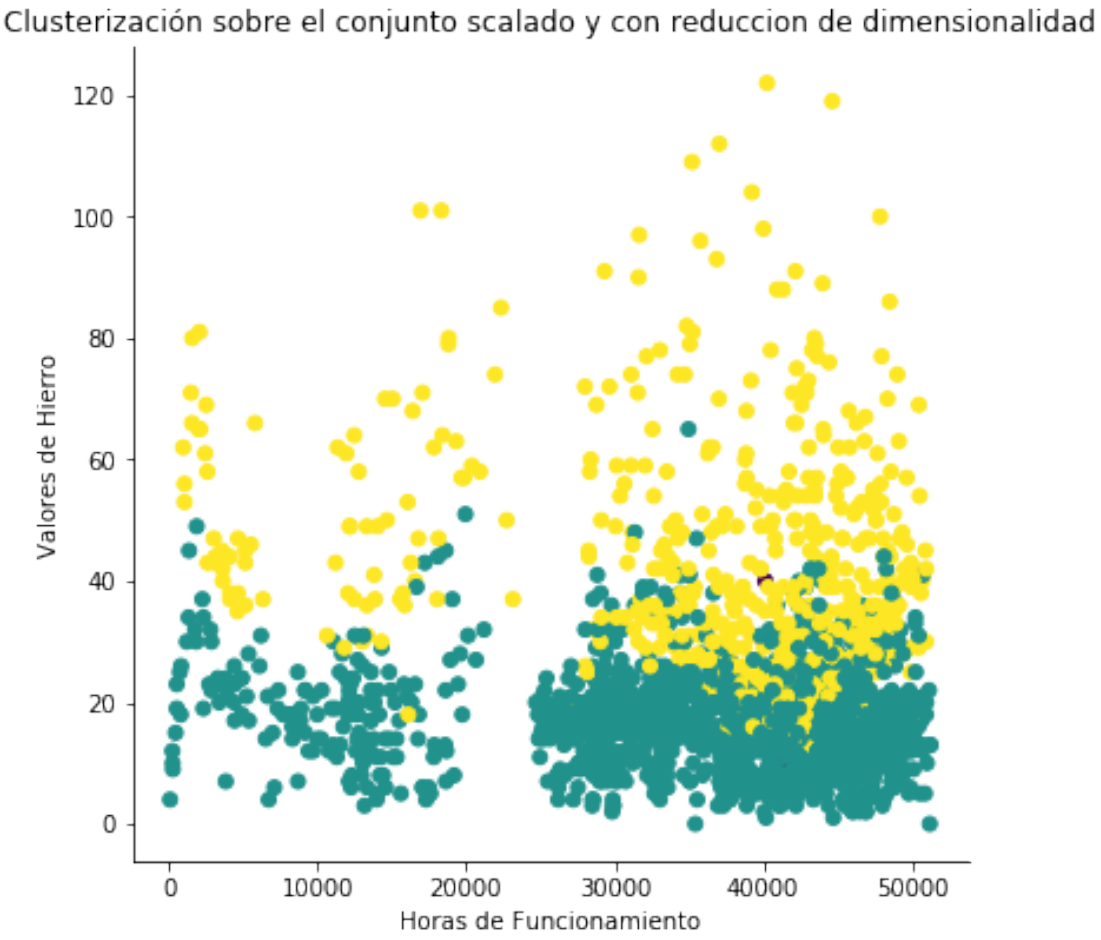

Observamos que alcanzamos una mejora mayor en los resultados, aunque no es óptima
El algoritmo identifica mejor 2 de las 3 clases, que en este caso son las mayoritarias.

[ ]: